Especificação Técnica de Requisitos e Arquitetura de Referência

Bank OnlineX — Módulo de Investimentos Financeiros

Resumo Executivo da Arquitetura: Este documento estabelece a especificação técnica oficial para o novo módulo de investimentos do Bank OnlineX. A solução atende a requisitos de alta transação de dados (10.000 TPS nominais / 25.000 TPS de pico), utilizando uma arquitetura reativa em Kubernetes, backbone de mensageria com Apache Kafka, cache em Redis Cluster e um ecossistema de Inteligência Artificial governado via protocolo MCP.

1. Visão Geral e Diretrizes da Solução de Investimentos

A transformação do módulo de investimentos do Bank OnlineX responde à necessidade de sustentar operações financeiras em um ambiente de banco digital caracterizado por picos extremos de tráfego durante o funcionamento dos mercados. A solução resolve gargalos de escalabilidade e latência das estruturas tradicionais, estabelecendo uma plataforma resiliente e geograficamente distribuída em nuvem.

Premissas Operacionais e Restrições de Engenharia:

- **Volumetria de Pico:** Suporte nominal a 10.000 TPS sustentados e picos instantâneos de até 25.000 TPS (crescimento de 40% a.a.).
- **Conformidade Regulatória:** Cumprimento estrito da LGPD e resoluções do BACEN, com trilhas imutáveis de auditoria WORM.
- **Compatibilidade Tecnológica:** Implantação obrigatória em clusters Kubernetes gerenciados sem afinidade de sessão (stateless).
- **Otimização de Ativos & Dados:** Reuso de plataformas corporativas (LLMs, n8n, observabilidade) com anonimização total de dados.

2. Especificação Formal de Requisitos do Sistema

2.1 Requisitos Funcionais de Negócio

- **Catálogo e Simulação de Produtos:** Consulta a CDBs, Tesouro Direto, ações, FIIs e cripto, com simulação dinâmica de rentabilidade.
- **Gestão e Execução de Ordens:** Emissão, cancelamento e acompanhamento de ordens com chave de idempotência no Redis.
- **Consolidação de Carteira em Tempo Quase Real:** Visualização de posições, saldo projetado e proventos atualizada via CQRS.
- **Recomendação Inteligente de Investimentos:** Acesso a teses personalizadas geradas por IA (RAG) com citação de fontes.
- **Movimentação Financeira e Operacional:** Transferência entre conta corrente e investimentos integrada ao Core Bancário.
- **Dashboards de Risco e Liquidez:** Painéis operacionais para monitoramento da exposição agregada e limites corporativos.

2.2 Requisitos Não-Funcionais e Objetivos de Nível de Serviço (SLOs)

ID	Requisito Não-Funcional	Meta de Desempenho (SLO)	Estratégia Arquitetural
RNF-01	Disponibilidade	99,95% (máx 4h22 indispo/ano)	Implantação Multi-AZ em 3 zonas, clusters ativo-ativo e failover automático.
RNF-02	Throughput Transacional	10.000 TPS nominais / 25.000 pico	Microsserviços em K8s com HPA e desacoplamento assíncrono via Apache Kafka.
RNF-03	Latência de Resposta	P95 < 300 ms (consultas) / P99 < 800 ms (ordens)	Caching agressivo em Redis Cluster, réplicas de leitura PostgreSQL e CQRS.
RNF-04	Escalabilidade Sistemática	Suporte ao crescimento anual de 40%	Pods stateless escalando por CPU/TPS sem afinidade de sessão.
RNF-05	Segurança da Informação	TLS 1.3 em trânsito / AES-256 em repouso	Arquitetura Zero Trust, mTLS interno, Vault para segredos e HSM para chaves.
RNF-06	Auditabilidade Operacional	100% das ordens com trilha imutável	Event sourcing nativo no Kafka com persistência em armazenamento WORM.
RNF-07	Observabilidade Avançada	MTTD < 5 min / MTTR < 30 min	Métricas, logs e traces via OpenTelemetry, Prometheus, Grafana e ELK.
RNF-08	Recuperação de Desastres	RPO ≤ 5 min / RTO ≤ 60 min	Replicação assíncrona cross-region, backups contínuos e runbooks de DR.

3. Arquitetura de Referência TO-BE e Decisões de Arquitetura

A solução adota o padrão de microsserviços reativos e orientados a eventos (Event-Driven Architecture), estruturados em dez camadas tecnológicas com isolamento de falhas.

Registros de Decisão de Arquitetura (ADRs):

- **ADR-001 (Event-Driven com Kafka):** Ordens e alterações de posição trafegam como eventos imutáveis no Kafka (RF=3).
- **ADR-002 (Microsserviços Stateless em K8s):** Aplicações sem estado local, permitindo HPA dinâmico no Kubernetes.
- **ADR-003 (API Gateway Centralizado):** Ponto único de autenticação OIDC, autorização JWT, rate limiting e gestão de cotas.
- **ADR-004 (Padrão CQRS Leve):** Escritas OLTP no banco primário e leituras em réplicas de leitura/Redis (P95 < 300 ms).
- **ADR-005 (IA Desacoplada via MCP):** Agentes de IA acessam ferramentas e dados exclusivamente via servidores MCP governados.

4. Arquitetura das Plataformas de Inteligência Artificial (AS-IS)

O Bank OnlineX opera um ecossistema de IA composto por cinco plataformas integradas que fornecem recomendações personalizadas e automações com estrita governança operacional:

- **Modelos de Linguagem (LLMs):** APIs gerenciadas com guardrails de segurança e sem retenção de dados sensíveis.
- **Agentes de IA Autônomos:** Loops de planejamento-ação-observação com supervisão obrigatória (human-in-the-loop).
- **Mecanismo RAG:** Busca semântica em banco vetorial para indexação de lâminas de produtos e normativos.

- **Orquestrador n8n:** Automação low-code de workflows multicanal disparados por eventos do Kafka.
- **Protocolo MCP:** Servidores MCP padronizados que expõem APIs e dados aos agentes de IA de forma segura.

5. Modelagem de Domínio e Fluxos Transacionais

5.1 Matriz de Atores e Casos de Uso (UML)

Ator do Sistema	Casos de Uso Associados	Premissas & Governança
Cliente (Investidor)	Consultar catálogo, simular, emitir ordens, acompanhar carteira, conversar com IA.	Leituras de alta frequência com SLO P95 < 300 ms.
Assessor Humano	Aprovar recomendações da IA, ajustar suitability, revisar alertas de compliance.	Ponto obrigatório de validação human-in-the-loop.
Agente de IA	Gerar recomendações RAG, monitorar carteira e notificar eventos de mercado.	Ações irreversíveis exigem aprovação prévia.
Core Bancário	Reservar saldo, liquidar operações financeiras e efetuar estornos.	Integração síncrona com timeout e compensação.
Market Data	Fornecer cotações de mercado em tempo real por streaming.	Bufferização inicial em Redis Cluster.

5.2 Modelo de Domínio e Agregados (DDD)

Entidade / Agregado	Atributos Principais	Relacionamentos DDD	Serviço Proprietário
Cliente	id, nome, cpfAnonimizado, perfilRisco, statusKYC	1—N ContaInvestimento; 1—N Ordem	Serviço de Conta
ContaInvestimento	id, saldoDisponivel, saldoReservado	1—N Posicao; pertence a Cliente	Serviço de Conta
Ordem	id, tipo, ativo, quantidade, precoLimite, status, idempotencyKey	Referencia Cliente e Ativo	Serviço de Ordens
Ativo	ticker, classe, grauRisco	N—N Produto; cotado por Cotacao	Serviço de Cotações
Posicao	ativo, quantidadeMedia, precoMedio, proventos	Pertence a ContaInvestimento	Serviço de Carteira
Recomendacao	id, teseRAG, score, aprovacaoHumana	Associada a Cliente e Ativo	Agente de IA

6. Plano de Execução da POC, KPIs e Matriz de Riscos

6.1 Cronograma de Execução (6 Etapas em 10 Semanas)

Etapa	Duração	Atividades Principais	Critério de Aceite (Go/No-Go)
1. Preparação	1 sem	Coleta/anonimização de fontes, repositório e validação de grounding.	Cobertura total de fontes com grounding validado.
2. Modelagem UML	2 sem	Geração assistida dos 5 diagramas UML e revisão técnica.	Diagramas aprovados em design review.
3. Topologia e Sizing	1 sem	Dimensionamento Multi-AZ de pods K8s, Kafka e banco com folga.	Sizing atende RNF-01 e RNF-02 com 30% de folga.
4. Protótipo de Carga	3 sem	Construção do fluxo crítico e testes de estresse automatizados.	Sustentação de 10.000 TPS com P99 < 800 ms.

Etapa	Duração	Atividades Principais	Critério de Aceite (Go/No-Go)
5. Integração com IA	2 sem	Agente RAG, integração MCP e automações n8n.	Recomendações com citação e aprovação humana.
6. Consolidação	1 sem	Lições aprendidas, estimativa de custos e roadmap final.	Aprovação formal do comitê de arquitetura.

6.2 Indicadores Chave de Desempenho (KPIs de Aceite)

- **KPI-01 (Desempenho Transacional):** Sustentação de 10.000 TPS com P99 < 800 ms e P95 < 300 ms.
- **KPI-02 (Rastreabilidade das Decisões):** 100% das afirmações técnicas embasadas em fontes oficiais.
- **KPI-03 (Qualidade da Modelagem):** Zero divergências críticas entre diagramas UML e requisitos.
- **KPI-04 (IA Governada):** Toda recomendação com citação da base e aprovação humana registrada.
- **KPI-05 (Precisão Orçamentária):** Custos em nuvem estimados com variação máxima de ±20%.