RELATÓRIO DE TOPOLOGIA MULTI-AZ E SIZING DE INFRAESTRUTURA

ETAPA 3 (SEMANA 4) — DIMENSIONAMENTO DE CAPACIDADE (+30% HEADROOM)

Bank OnlineX | Módulo de Investimentos Financeiros de Alta Volumetria | Código: POC-ARQ-ETAPA3-SIZING-v1.0

1. VISÃO GERAL E OBJETIVOS DA ETAPA 3 (SEMANA 4)

A Etapa 3 da Prova de Conceito (POC) do Bank OnlineX tem como objetivo central homologar a arquitetura de referência para o módulo de investimentos financeiros de alta volumetria. Esta fase estabelece a topologia Multi-AZ detalhada e a Matriz de Sizing de Infraestrutura necessária para sustentar picos extremos de tráfego transacional de mercado, atendendo plenamente aos Requisitos Não-Funcionais (SLOs) com a margem de segurança exigida pelo comitê de engenharia.

SUMÁRIO DOS PARÂMETROS CHAVE DE DESEMPENHO (ETAPA 3)
Meta Volumétrica Principal: Sustentar 10.000 TPS nominais e picos de 25.000 TPS.
Margem de Segurança Exigida: Mínimo de 30% de folga (headroom) sobre o pico máximo (Capacidade Alvo: **32.500 TPS**).
SLOs Chave: Disponibilidade ≥ 99,95% (RNF-01), Latência P99 < 800 ms (ordens) e P95 < 300 ms (consultas — RNF-03).

2. PREMISSAS VOLUMÉTRICAS E MARGEM DE SEGURANÇA (HEADROOM)

O dimensionamento dos recursos foi projetado considerando a volatilidade dos mercados financeiros e um crescimento anual estimado em 40% ao ano (RNF-04). Para evitar gargalos de saturação em momentos de alta volatilidade, a infraestrutura foi dimensionada para uma capacidade operacional de 32.500 TPS, garantindo que nenhum componente opere acima de 70% de sua capacidade máxima no pico.

Parâmetro Volumétrico	Valor de Projeto	Estratégia de Engenharia Aplicada
Throughput Nominal Sustentado	10.000 TPS	Processamento contínuo sem degradação de latência (165 Pods em baseline).
Pico Instantâneo de Mercado	25.000 TPS	Auto-scaling horizontal (HPA) e desacoplamento assíncrono via Apache Kafka.
Capacidade Projetada (Headroom)	32.500 TPS	30% de folga de segurança sobre o pico máximo (Critério Go/No-Go da Etapa 3).
Taxa de Crescimento Anual	+40% ao ano	Arquitetura reativa baseada em pods 100% stateless em Kubernetes (RNF-04).
Topologia Física e Lógica	3 AZs Ativo-Ativo	Distribuição simétrica em 3 Zonas de Disponibilidade (AZ-a, AZ-b, AZ-c) com failover automático.

3. MATRIZ DE DIMENSIONAMENTO DE INFRAESTRUTURA (SIZING MATRIX)

A tabela a seguir apresenta o detalhamento de recursos por camada tecnológica. Todos os serviços de aplicação rodam em pods stateless gerenciados pelo Kubernetes com suporte a HPA (Horizontal Pod Autoscaler), enquanto as camadas de dados e mensageria utilizam clusters distribuídos Multi-AZ sobre 27 Worker Nodes c6i.8xlarge (32 vCPU, 64 GB RAM):

Camada	Componente	Especificação Unitária	Baseline (10k TPS)	Pico c/ +30% Folga (32,5k TPS)	Justificativa Arquitetural
Borda / Ingress	Load Balancer L7 / WAF	Managed Ingress Multi-AZ	3 Instâncias	Autoscaling até 32,5k RPS	Proteção DDoS, TLS 1.3 e WAF na borda
Camada Web	Cluster Nginx (Reverse Proxy)	2 vCPU, 4 GB RAM	12 Pods (4/AZ)	18 Pods (6/AZ)	Servir SPA/PWA e roteamento BFF

Camada	Componente	Especificação Unitária	Baseline (10k TPS)	Pico c/ +30% Folga (32,5k TPS)	Justificativa Arquitetural
Gateway & BFF	API Gateway Pods	4 vCPU, 8 GB RAM	24 Pods (8/AZ)	40 Pods (14/AZ)	AuthN OIDC, JWT e Rate Limit (ADR-003)
Aplicação	Serviço de Ordens	4 vCPU, 8 GB RAM	42 Pods (14/AZ)	60 Pods (20/AZ)	Validação e escrita no Kafka (ADR-001)
Aplicação	Serviço de Risco & PLD	2 vCPU, 4 GB RAM	28 Pods (10/AZ)	40 Pods (14/AZ)	Suitability e PLD síncrono
Aplicação	Serviço de Carteira	4 vCPU, 8 GB RAM	33 Pods (11/AZ)	48 Pods (16/AZ)	Consumo Kafka 1:1 (48 partições) e CQRS
Aplicação	Serviço de Conta & Core	2 vCPU, 4 GB RAM	12 Pods (4/AZ)	15 Pods (5/AZ)	Reserva de saldo e liquidação Core
Aplicação	Serviço de Cotações	2 vCPU, 4 GB RAM	8 Pods (3/AZ)	9 Pods (3/AZ)	Ingestão Market Data no Redis/Kafka
Ecossistema IA	Agente RAG, n8n & MCP	4 a 8 vCPU, 16 GB RAM	6 Pods (2/AZ)	6 Pods + 5 MCP	Isolamento IA via protocolo MCP (ADR-005)
Mensageria	Cluster Apache Kafka	16 vCPU, 64 GB, NVMe	6 Brokers + 3 KRaft	6 Brokers (48 part/tópico)	Backbone imutável RF=3, acks=all (RPO=0)
Cache	Redis Cluster	8 vCPU, 32 GB RAM	6 Shards	12 Nós (6M + 6R, 128 GB)	Cache cotações (P95 < 300ms) e idempotência
Banco OLTP	PostgreSQL Primário/Standby	64 vCPU, 256 GB RAM	1 Prim + 1 Standby	1 Prim + 1 Standby (PgBouncer)	Escritas OLTP e replicação síncrona Multi-AZ
Leitura OLTP	PostgreSQL Read Replicas	32 vCPU, 128 GB RAM	3 Réplicas	3 Réplicas (1 por AZ)	Leituras CQRS P95 < 300 ms (ADR-004)

4. TOPOLOGIA DE INFRAESTRUTURA MULTI-AZ (TO-BE)

A arquitetura TO-BE é estruturada de forma distribuída em 3 Zonas de Disponibilidade (AZ-a, AZ-b, AZ-c) no padrão Ativo-Ativo. A comunicação entre componentes segue diretrizes de alta resiliência, isolamento de falhas e baixa latência:

• **Camada Perimetral e Gateway:** Tráfego filtrado por CDN/WAF e Load Balancer L7 com terminação TLS 1.3, distribuído entre os pods do API Gateway.

• **Microsserviços Stateless (K8s HPA):** Executados em cluster Kubernetes gerenciado (27 Worker Nodes c6i.8xlarge), escalando automaticamente de 165 pods (baseline) para 236 pods no pico.

• **Backbone de Mensageria (Apache Kafka):** 6 Brokers distribuídos (2 por AZ) com fator de replicação RF=3 e min.insync.replicas=2, garantindo zero perda de dados (RPO=0).

• **Persistência & Cache (CQRS):** Redis Cluster distribuído com 12 nós (6 Masters + 6 Réplicas, 128 GB RAM útil) para cache de sessão e idempotência; PostgreSQL com 1 nó primário de escrita, 1 standby síncrono e 3 réplicas de leitura otimizadas via PgBouncer.

5. VALIDAÇÃO DE SLOS E CRITÉRIOS DE ACEITE GO/NO-GO (ETAPA 3)

A homologação da Etapa 3 condiciona o prosseguimento da POC para a Etapa 4 (Protótipo de Carga). A análise arquitetural confirma o atendimento integral a todos os critérios estabelecidos:

Requisito Não-Funcional	Meta de Desempenho (SLO)	Resultado do Sizing Homologado	Status Go/No-Go
RNF-01: Disponibilidade	99,95% (máx 4h22 indispo/ano)	Multi-AZ Ativo-Ativo em 3 AZs com failover automático e tolerância à perda de 1 AZ inteira.	**APROVADO (GO)**
RNF-02: Throughput	10.000 TPS nominais / 25.000 pico	Dimensionado para 32.500 TPS (+30% de folga de segurança) com 236 Pods e 48 partições Kafka.	**APROVADO (GO)**
RNF-03: Latência	P95 < 300 ms (consultas) P99 < 800 ms (ordens)	Redis Cluster (128 GB) + 3 Réplicas CQRS + Particionamento Kafka 1:1 por cliente_id.	**APROVADO (GO)**
RNF-04: Escalabilidade	Suporte a +40% crescimento ao ano	Pods 100% stateless em K8s com HPA (scale-up em 62s) e desacoplamento assíncrono.	**APROVADO (GO)**

Conclusão & Próximos Passos (Etapa 4): Com a aprovação formal do sizing da Etapa 3, o projeto está autorizado a avançar para a **Etapa 4 (Protótipo de Carga — Semanas 5 a 7)**, onde será construída a implementação mínima do fluxo crítico (API Gateway → Serviço de Ordens → Kafka → Serviço de Carteira) e executado o teste de estresse automatizado.

Aprovado por: Comitê de Arquitetura de Soluções e Engenharia de Software — Bank OnlineX

Patrocinador do Projeto: Diretoria de Tecnologia e Operações Financeiras

Data de Homologação: Novembro de 2026 | **Documento Oficial:** POC-ARQ-ETAPA3-SIZING-v1.0

Código de Controle do Artefato: fase-3-relatorio-sizing-bank-onlinex.pdf