PLANO DE TESTES DE CARGA E OBSERVABILIDADE

Etapa 4 da Prova de Conceito (POC) — Bank OnlineX

1. Visão Geral e Objetivos da Etapa 4

A **Etapa 4 da Prova de Conceito (POC)** do Bank OnlineX abrange o período das Semanas 5 a 7 e foca no desenvolvimento do protótipo funcional mínimo do fluxo crítico transacional e na realização dos testes de carga automatizados. O objetivo central é comprovar empiricamente que a arquitetura proposta sustenta a carga nominal de **10.000 TPS com P99 < 800 ms** no processamento de ordens e **P95 < 300 ms** nas consultas de carteira, validando o critério formal de aceite **KPI-01**.

> **RESUMO DOS PARÂMETROS DA ETAPA 4**
> **Meta Volumétrica Sustentada:** 10.000 TPS nominais com suporte a picos de 25.000 TPS.
> **Capacidade Testada com Folga (Headroom 30%):** 32.500 TPS nos cenários de estresse máximo.
> **SLOs Primários:** Latência de Emissão de Ordens P99 < 800 ms | Latência de Consultas P95 < 300 ms | Disponibilidade 99,95%.

2. Escopo do Protótipo Mínimo (MVP do Fluxo Crítico)

O protótipo é construído com foco estrito na esteira de alta frequência de emissão e liquidação de ordens, desacoplada via Apache Kafka e regida pelos ADRs-001 a 004:

- **API Gateway & BFF:** Recepção de POST /ordens, validação JWT, rate-limiting e deduplicação inicial.
- **Serviço de Ordens:** Controle de idempotência no Redis Cluster, consulta síncrona ao Serviço de Risco (Suitability e PLD) e emissão do evento ordens.criadas no Kafka.
- **Backbone Apache Kafka:** Tópicos particionados por cliente (48 partições por tópico crítico, RF=3, min.insync.replicas=2) garantindo ordenação por investidor.
- **Serviço de Carteira:** Consumo assíncrono (CQRS), chamada de liquidação/reserva ao Core Bancário e publicação dos eventos PosicaoAtualizada e OrdemExecutada.
- **Tratamento do Fluxo Alternativo:** Rejeição por saldo insuficiente emitindo evento OrdemRejeitada e HTTP 422, sem estados intermediários parciais.

3. Matriz de Cenários de Testes de Carga

Os testes de estresse serão executados em ambiente de homologação idêntico à topologia Multi-AZ dimensionada na Etapa 3 (60 Pods de Ordens, 48 Pods de Carteira, 6 Brokers Kafka e 12 nós Redis Cluster). Serão aplicados três cenários progressivos:

Cenário de Teste	Throughput Alvo	Duração	SLO Esperado	Objetivo de Engenharia
1. Carga Nominal Sustentada	10.000 TPS	30 min	P99 < 800 ms P95 < 300 ms	Validar a estabilidade térmica da aplicação, consumo de memória dos pods e latência constante.
2. Picos Instantâneos de Mercado	25.000 TPS	15 min (rampa de 2 min)	P99 < 800 ms Zero perda de dados	Testar o tempo de reação do HPA (Autoscaling) do Kubernetes e amortecimento de picos via Kafka.
3. Ruptura e Margem (Headroom 30%)	32.500 TPS	10 min	Degradação graciosa HTTP 429 / Rate Limit	Validar a margem de segurança de 30%, resiliência dos circuitos de proteção e comportamento do PgBouncer.

4. Roteiro e Execution Scripts (k6 & Locust)

A automação de carga utilizará o **k6** para injeção distribuída de tráfego HTTP/REST e WebSocket. Abaixo apresenta-se o trecho do script de estresse homologado para execução da POC:

```
import http from 'k6/http';
import { check, sleep } from 'k6';

export const options = {
  stages: [
    { duration: '2m', target: 10000 },  // Rampa para carga nominal
    { duration: '30m', target: 10000 }, // Sustentado 10k TPS
    { duration: '2m', target: 25000 },  // Rampup para pico
    { duration: '15m', target: 25000 }, // Sustentado 25k TPS
    { duration: '1m', target: 32500 },  // Teste de Headroom (30%)
    { duration: '10m', target: 32500 }, // Ruptura controlada
    { duration: '2m', target: 0 },      // Rampa de descida
  ],
  thresholds: {
    http_req_duration: ['p(99)<800', 'p(95)<300'], // SLOs de Latência
    http_req_failed: ['rate<0.0005'],               // Erros < 0.05%
  },
};

export default function () {
  const url = 'https://gateway.bankonlinex.internal/v1/ordens';
  const payload = JSON.stringify({
    clienteId: `CLI-${__VU}`,
    ticker: 'PETR4',
    quantidade: 100,
    precoLimite: 32.50,
    tipo: 'COMPRA',
    idempotencyKey: `IDEMP-${__VU}-${__ITER}`
  });
  const params = { headers: { 'Content-Type': 'application/json', 'Authorization': 'Bearer token-jwt-test' }
 };
  const res = http.post(url, payload, params);
  check(res, { 'status 201 ou 422': (r) => r.status === 201 || r.status === 422 });
  sleep(0.1);
}
```

5. Arquitetura de Observabilidade e Telemetria

Para a correlação e diagnóstico imediato de gargalos durante os testes de estresse, a infraestrutura será monitorada continuamente pela stack unificada baseada em OpenTelemetry (RNF-07):

Pilar de Telemetria	Ferramenta / Stack	Métricas & Painéis Monitorados	Meta de Diagnóstico
Métricas de Sistema	Prometheus & Grafana	CPU/RAM Pods K8s, Partições Kafka, Hit-ratio Redis, IOPS PostgreSQL.	Dashboards de saturação em tempo real.
Distributed Tracing	OpenTelemetry & Jaeger	Latência end-to-end: Gateway -> Ordens -> Kafka -> Carteira -> Core.	MTTD < 5 min para identificação de gargalos.
Log Management	FluentBit & ELK Stack	Logs estruturados JSON com traceID correlacionado e logs de liquidação.	Auditoria e rastreamento de exceções.
Alertas de SLO	Alertmanager	Gatilhos acionados se P99 > 700 ms ou taxa de erros > 0,01%.	Notificação imediata para a equipe de testes.

6. Critérios de Aceite Go/No-Go e Matriz de Riscos

Indicador / KPI	Meta Exigida	Mecanismo de Validação	Status / Critério
KPI-01: Desempenho Transacional	10.000 TPS com P99 < 800 ms	Relatório exportado do k6 e Grafana	Obrigatório para aprovação da Etapa 4
Auditabilidade das Ordens	100% das ordens com trace imutável	Validação de offset no Apache Kafka	Zero perda de eventos (RPO = 0)
Idempotência Transacional	Zero duplicidade em rajadas	Validação de chaves duplicadas no Redis	Retorno imediato de requisições idênticas
Recuperação por Saldo	HTTP 422 em saldo insuficiente	Injeção de contas sem saldo no k6	Sem estados intermediários parciais

Conclusão da Etapa 4: Com a execução bem-sucedida destes cenários e a homologação dos relatórios k6, a POC receberá a chancela formal para avançar para a **Etapa 5 (Integração com IA e Governança MCP)**.