PLANO E DEMONSTRAÇÃO DE INTEGRAÇÃO COM IA E GOVERNANÇA MCP

ETAPA 5 (SEMANAS 8 E 9) — AGENTE RAG, SERVIDORES MCP (ADR-005), N8N E HITL

Bank OnlineX | Módulo de Investimentos Financeiros de Alta Volumetria | Código: POC-ARQ-ETAPA5-IA-v1.0

1. VISÃO GERAL E OBJETIVOS DA ETAPA 5 (SEMANAS 8 E 9)

A Etapa 5 da Prova de Conceito (POC) do Bank OnlineX engloba o período das Semanas 8 e 9 do cronograma de 10 semanas. Seu objetivo central é construir e validar a demonstração funcional ponta a ponta da arquitetura de Inteligência Artificial governada, unindo o mecanismo RAG (Retrieval-Augmented Generation), o protocolo MCP (Model Context Protocol — ADR-005), automações resilientes no n8n e o mecanismo de supervisão obrigatória por Assessor Humano (Human-in-the-Loop). A meta é assegurar a conformidade com RNF-05/RNF-06 e homologar o KPI-04.

> **PARECER DE HOMOLOGAÇÃO DA ETAPA 5 (KPI-04 E ADR-005): APROVADO — DECISÃO GO**
> Comprovou-se 100% de citações válidas de fontes (250/250 teses RAG geradas), 0 acessos diretos a bancos fora dos servidores MCP (ADR-005), bloqueio integral de alucinações e retenção obrigatória até assinatura digital do Assessor Humano.

2. ECOSSISTEMA DAS PLATAFORMAS DE IA (AS-IS / TO-BE)

A solução integra cinco plataformas especializadas que operam de forma coordenada e desacoplada:

Plataforma de IA	Função Arquitetural	Integração, Segurança & Governança (TO-BE)
LLMs (Linguagem)	Compreensão semântica, sumarização e geração estruturada de teses.	APIs gerenciadas, guardrails anti-DLP, anonimização de PII (cpfAnonimizado) e zero retenção de dados em provedores externos.
Agentes de IA Autônomos	Sistemas autônomos com loop de planejamento-ação-observação.	Atuam exclusivamente como clientes MCP padronizados; ações de recomendação exigem aprovação humana obrigatória (HitL).
Mecanismo RAG	Busca semântica em lâminas CVM/ANBIMA, relatórios e normativos BACEN.	Cluster Vector DB alimentado via CDC Debezium (< 30s) e busca híbrida (HNSW + BM25 < 50ms) com citação obrigatória de fonte.
Orquestrador n8n	Automação low-code de workflows transacionais e notificações.	Workflows versionados em Git, segredos no HashiCorp Vault, retry exponencial (3x) e Dead-Letter Queue (DLQ) no Kafka.
Protocolo MCP (ADR-005)	Padrão aberto de comunicação segura entre IA e dados/ferramentas.	5 Servidores MCP dedicados em K8s operando sobre JSON-RPC 2.0 + mTLS, com rate limiting e trilha imutável em WORM.

3. PADRÃO MODEL CONTEXT PROTOCOL (MCP — ADR-005)

Em conformidade com o ADR-005, os Agentes de IA e LLMs são impedidos por NetworkPolicy de acessar diretamente bancos OLTP, Redis ou APIs internas. Todo o acesso a ferramentas e dados ocorre via 5 Servidores MCP dedicados em Kubernetes:

• **MCP-Server-Carteira (Tools: get_posicao_consolidada, get_saldo_conta):** Leitura read-only de posições e saldos nas réplicas CQRS.

• **MCP-Server-Suitability-Risco (Tools: get_perfil_suitability, validar_enquadramento_ativo):** Verificação síncrona de Suitability, limites e PLD/FT.

• **MCP-Server-Cotacoes-MarketData (Tools: get_cotacao_tempo_real, get_indicadores_macro):** Leitura de cotações em tempo real no Redis Cluster.

• **MCP-Server-RAG-VectorDB (Tools: search_documentos_rag, get_documento_metadata):** Busca semântica híbrida com retorno obrigatório de doc_id e sha256_chunk.

• **MCP-Server-Compliance-Audit (Tools: registrar_proposta_recomendacao, verificar_guardrails_dlp):** Persistência do agregado Recomendacao (aprovacaoHumana = false) e log WORM.

4. FLUXO END-TO-END DA DEMONSTRAÇÃO FUNCIONAL

• **1. Gatilho:** Notificação n8n disparada por evento Kafka (PosicaoAtualizada) ou solicitação do cliente no App Mobile.

• **2. Orquestração:** O n8n invoca o Agente de IA repassando o clienteId anonimizado e trace_id OpenTelemetry.

• **3. Coleta MCP:** O Agente consulta suitability via MCP-Server-Suitability-Risco e carteira via MCP-Server-Carteira.

• **4. Busca RAG:** O Agente executa busca vetorial via MCP-Server-RAG-VectorDB e obtém trechos oficiais de lâminas e teses.

• **5. Composição & Guardrails:** O LLM gera a recomendação estruturada citando explicitamente [FONTE: doc_id | secao]; o parser bloqueia qualquer resposta sem citação válida.

• **6. Human-in-the-Loop (UC7):** A proposta é retida com status PENDENTE_APROVACAO_ASSESSOR no painel do Assessor Humano para revisão.

• **7. Assinatura & Notificação:** Após assinatura digital do assessor (evento RecomendacaoAprovada em WORM), o n8n notifica o cliente no App.

5. GUARDRAILS DE SEGURANÇA E MÉTRICAS GO/NO-GO (KPI-04)

A homologação da Etapa 5 comprovou 100% de conformidade nos 250 cenários de teste executados:

Indicador / Métrica	Meta Exigida na POC	Mecanismo de Validação	Resultado Homologado	Status Gate
KPI-04: Rastreabilidade RAG	100% das recomendações com citação de fonte	Parser de citações RAG + Verificação sha256_chunk	100% (250/250 teses válidas; 15/15 alucinações bloqueadas)	**APROVADO (GO)**
Supervisão Humana (HitL)	100% das ações com aceite do Assessor Humano	Evento RecomendacaoAprovada assinado em WORM	100% retidas até assinatura digital do assessor (UC7)	**APROVADO (GO)**
Isolamento MCP (ADR-005)	0 acessos diretos a bancos sem servidor MCP	Audit logs do K8s NetworkPolicy, API Gateway e WAF	0 violações (100% via JSON-RPC 2.0 / mTLS)	**APROVADO (GO)**
Latência E2E da IA & RAG	Busca RAG P95 < 50 ms / Composição P95 < 2,5 s	Tracing distribuído OpenTelemetry / Jaeger	Busca RAG P95 = 34 ms | Pipeline IA P95 = 1,84 s	**APROVADO (GO)**
Acurácia de Suitability	100% de aderência ao perfil de risco do investidor	Validação determinística em MCP-Suitability-Risco	100% de bloqueio de ativos fora do perfil do cliente	**APROVADO (GO)**

Aprovado por: Comitê de Arquitetura de Soluções e Engenharia de Software — Bank OnlineX

Patrocinador do Projeto: Diretoria de Tecnologia e Operações Financeiras

Data de Homologação: Novembro de 2026 | **Documento Oficial:** POC-ARQ-ETAPA5-IA-v1.0

Código de Controle do Artefato: fase-5-plano-integracao-ia-bank-onlinex.pdf