Especificação Técnica — Etapa 5 da POC

Plano de Integração com IA e Governança MCP

Demonstração Funcional de IA Generativa, RAG, MCP (ADR-005), n8n e Human-in-the-Loop

1. Visão Geral e Objetivos da Etapa 5 (Semanas 8 e 9)

A Etapa 5 da Prova de Conceito (POC) do Bank OnlineX engloba o período das Semanas 8 e 9 do cronograma de 10 semanas. Seu objetivo central é construir e validar a demonstração funcional ponta a ponta da arquitetura de Inteligência Artificial governada, unindo o mecanismo RAG (Retrieval-Augmented Generation), o protocolo MCP (Model Context Protocol - ADR-005), automações no n8n e o mecanismo de supervisão obrigatória por Assessor Humano (human-in-the-loop). A meta é assegurar a conformidade com RNF-05/RNF-06 e homologar o KPI-04.

2. Ecossistema das Plataformas de IA (AS-IS / TO-BE)

A solução integra cinco plataformas especializadas que operam de forma coordenada e desacoplada:

Plataforma	Função Arquitetural	Integração & Governança
LLMs (Linguagem)	Compreensão semântica e geração de teses	APIs gerenciadas, guardrails anti-DLP, sem retenção de dados.
Agentes de IA	Sistemas autônomos com loop planejamento-ação	Clientes MCP padronizados; aprovação humana obrigatória.
Mecanismo RAG	Busca semântica em lâminas e normativos BACEN	Vector DB via CDC; obrigatoriedade de citação de fontes.
Orquestrador n8n	Automação low-code de workflows e notificações	Workflows Git, segredos no Vault, conectores Kafka.
Protocolo MCP	Padrão aberto de comunicação com dados/ferramentas	Servidores MCP (ADR-005), JSON-RPC 2.0, mTLS e logs WORM.

3. Padrão Model Context Protocol (MCP - ADR-005)

Em conformidade com o ADR-005, os Agentes de IA e LLMs são impedidos de acessar diretamente bancos OLTP, Redis ou APIs internas. Todo o acesso a ferramentas e dados ocorre via Servidores MCP dedicados em Kubernetes:

- **MCP-RiskCompliance:** Interface para suitability, limites operacionais e verificação de PLD/FT.
- **MCP-VectorDB:** Interface para consultas RAG sobre a base vetorial de lâminas e relatórios.
- **MCP-CoreBancario:** Interface para leitura de posições de carteira e saldos de investimento.
- **MCP-MarketData:** Interface para streaming de cotações de mercado e histórico de ativos.

4. Fluxo End-to-End da Demonstração Funcional

1. **Gatilho:** Notificação n8n disparada por evento Kafka ou solicitação do cliente no App Mobile.
2. **Orquestração:** n8n invoca o Agente de IA repassando o *clienteId* anonimizado.
3. **Coleta MCP:** Agente consulta suitability via *MCP-RiskCompliance* e saldo via *MCP-CoreBancario*.
4. **Busca RAG:** Agente faz busca vetorial via *MCP-VectorDB* e obtém trechos e teses de produtos.
5. **Composição:** LLM gera a recomendação estruturada citando explicitamente o trecho fonte.
6. **Human-in-the-Loop:** Proposta é retida no painel do Assessor Humano para revisão e aprovação.
7. **Execução:** Após assinatura do assessor, n8n notifica o cliente e disponibiliza o aceite no App.

5. Guardrails de Segurança e Métricas Go/No-Go (KPI-04)

A homologação da Etapa 5 exige 100% de conformidade com as regras de governança e rastreabilidade:

Indicador / Métrica	Meta Exigida	Mecanismo de Validação	Status / Critério
KPI-04: Rastreabilidade	100% das recomendações com citação	Parser de citações RAG + Log Kafka	OBRIGATÓRIO (Go)
Supervisão Humana (HitL)	100% das ações com aceite do assessor	Evento RecomendacaoAprovada assinado	OBRIGATÓRIO (Go)
Latência E2E da IA	P95 < 2,5s (da chamada ao painel)	Tracing OpenTelemetry / Jaeger	APROVADO (Go)
Isolamento MCP (ADR-005)	0 acessos diretos sem servidor MCP	Audit logs do API Gateway e WAF	OBRIGATÓRIO (Go)
Acurácia de Suitability	100% de aderência ao perfil do cliente	Validação síncrona em MCP-Risk	OBRIGATÓRIO (Go)