RELATÓRIO FINAL DE CONSOLIDAÇÃO E DECISÃO DE INVESTIMENTO — ETAPA 6

Bank OnlineX — Módulo de Investimentos de Alta Volumetria (POC 10 Semanas)

1. Resumo Executivo e Decisão Formal de Investimento

Este documento estabelece o parecer final da Prova de Conceito (POC) de 10 semanas para a nova plataforma de investimentos do **Bank OnlineX**. Com a conclusão de todas as 6 etapas planejadas — abrangendo a modelagem UML, o dimensionamento Multi-AZ, a validação empírica em testes de carga de 10.000 a 32.500 TPS e a demonstração funcional da governança de Inteligência Artificial via Model Context Protocol (MCP) —, o **Comitê de Arquitetura de Soluções e Engenharia** emite o parecer formal de **APROVAÇÃO UNÂNIME (DECISÃO GO)** para o avanço da solução ao ambiente de produção.

PARECER DO COMITÊ DE ARQUITETURA: APROVADO (DECISÃO GO)

Todos os 5 KPIs de Aceite (KPI-01 a KPI-05) e SLOs de Desempenho e Segurança foram 100% atingidos.

2. Quadro de Homologação dos Critérios de Sucesso (KPIs de Aceite)

A tabela a seguir apresenta a reconciliação dos 5 Indicadores Chave de Desempenho (KPIs) estabelecidos na especificações iniciais da POC, confrontando as metas exigidas com os resultados obtidos:

KPI / Indicador	Descrição & Meta Exigida	Resultado Aferido na POC	Status Go/No-Go
KPI-01: Desempenho Transacional	Sustentar 10.000 TPS nominais com latência P99 < 800 ms (ordens) e P95 < 300 ms (consultas).	10.042 TPS nominais (P99 = 380 ms) e 32.560 TPS pico +30% folga (P99 = 742 ms, P95 = 174 ms).	**GO (Aprovado)**
KPI-02: Rastreabilidade Arquitetural	100% das decisões embasadas com citação e grounding nas fontes oficiais do NotebookLM.	100% das especificações técnicas, ADRs e diagramas validados com rastreabilidade às fontes.	**GO (Aprovado)**
KPI-03: Qualidade da Modelagem UML	Zero divergências críticas entre os 5 diagramas formais UML/Mermaid e os requisitos de negócio.	0 divergências após design review dos diagramas de Casos de Uso, Componentes, Sequência, DDD e Implantação.	**GO (Aprovado)**
KPI-04: IA Governada & HitL	100% das recomendações RAG com citação de fonte e retenção para aprovação humana (HitL via MCP).	100% de citações válidas (250/250 teses) e retenção obrigatória até assinatura digital do assessor humano.	**GO (Aprovado)**
KPI-05: Precisão Orçamentária	Estimativa de custos em nuvem com variação máxima de ±20% em relação ao orçamento base.	Variação de +6,4% no orçamento anual (US$ 574.560,00 vs US$ 540.000,00 base), dentro do limite estipulado.	**GO (Aprovado)**

3. Estimativa Orçamentária Detalhada de Nuvem (KPI-05)

A infraestrutura de produção foi dimensionada considerando o modelo Multi-AZ em 3 Zonas de Disponibilidade (Ativo-Ativo) com suporte a 236 Pods Kubernetes no pico (32.500 TPS com 30% de folga). A tabela detalha o custo mensal e anual por camada:

Camada de Infraestrutura	Recursos / Instâncias Dimensionadas	Custo Mensal (USD)	Custo Anual (USD)	Participação (%)
Cluster Kubernetes (Workers)	27 Nódos c6i.8xlarge (32 vCPU, 64GB RAM) em 3 AZs	$ 18.500,00	$ 222.000,00	38,6%
Mensageria Apache Kafka	6 Brokers (16 vCPU, 64GB, NVMe RAID-0) + 3 KRaft Controller	$ 8.400,00	$ 100.800,00	17,5%
Cache Redis Cluster	12 Nós (6 Masters + 6 Réplicas) - 128 GB RAM Útil	$ 4.200,00	$ 50.400,00	8,8%
Persistência PostgreSQL	1 Primário (64 vCPU, 256GB) + 3 Réplicas Leitura (32 vCPU)	$ 7.600,00	$ 91.200,00	15,9%
Borda, CDN, WAF & LB	CDN Edge Security, WAF Managed & Load Balancers L7 Multi-AZ	$ 3.100,00	$ 37.200,00	6,5%
Ecossistema IA & MCP	3 Pods MCP, Cluster Vector DB & Pipeline RAG	$ 3.800,00	$ 45.600,00	7,9%
Observabilidade & Cofre	Prometheus/Grafana, OpenTelemetry, ELK & HashiCorp Vault/HSM	$ 2.280,00	$ 27.360,00	4,8%
TOTAL GERAL (PRODUÇÃO)	**Infraestrutura Completa Multi-AZ (+30% Folga / 32,5k TPS)**	**$ 47.880,00**	**$ 574.560,00**	**100,0%**

Análise da Variação Orçamentária: O orçamento base estimado para o projeto era de US$ 45.000,00 / mês (US$ 540.000,00 / ano). O dimensionamento final homologado de US$ 47.880,00 / mês (US$ 574.560,00 / ano) representa uma variação de apenas **+6,4%**, decorrente da expansão de réplicas de leitura do PostgreSQL e da adição do quórum dedicado KRaft no Kafka. A variação atende com folga ao critério de aceite do **KPI-05 (limite de ±20%)**.

4. Consolidação de Lições Aprendidas de Engenharia

• **Event Streaming com Apache Kafka (ADR-001):** Adoção de 48 partições por tópico crítico vinculadas à chave *cliente_id* garantiu consumo desacoplado em relação 1:1 com os 48 pods do Serviço de Carteira, sustentando 32.560 TPS com zero *consumer lag*.

• **Auto-Scaling em Kubernetes (ADR-002):** Pods 100% *stateless* permitiram escalamento horizontal dinâmico de 165 para 236 pods em 62 segundos durante rajadas de 25.000 TPS, sem perda de afinidade de sessão ou falhas em conexões HTTP.

• **Padrão CQRS Leve e Caching Aggressivo (ADR-004):** O desacoplamento entre escritas no OLTP e leituras no Redis Cluster (128 GB RAM) permitiu atingir latência P95 = 64 ms para consultas de carteira com *hit-ratio* de 99,4%.

• **Isolamento Estrito via Protocolo MCP (ADR-005):** O uso dos 5 servidores MCP impediu completamente o acesso direto de motores de IA a bancos de dados, eliminando 100% de tentativas de injeção e alucinações sem *grounding*.

5. Roadmap de Implantação em Produção (14 Semanas)

A transição do protótipo homologado para a operação corporativa definitiva será executada em 4 fases estruturadas:

Fase do Roadmap	Período	Entregáveis & Marcos Operacionais	Critério de Saída (Gate)
Fase A: Provisionamento & Zero Trust	Semanas 1 a 4	Provisionamento de infraestrutura Multi-AZ via Terraform, cluster Kubernetes produtivo, cofre HashiCorp Vault e mTLS.	Infraestrutura 100% provisionada com certs mTLS e testes de conectividade Zero Trust.
Fase B: Ingestão de Dados & RAG	Semanas 5 a 8	Carga inicial de dados, sincronização CDC Debezium, implantação do cluster Vector DB e servidores MCP de produção.	Pipeline RAG com latência P95 < 50 ms e sincronização CDC em < 30 segundos.
Fase C: Testes Integrados & Pentest	Semanas 9 a 11	Homologação integrada end-to-end, testes de invasão (Pentest) e simulação de Disaster Recovery (DR / Chaos).	Zero vulnerabilidades críticas e RTO ≤ 60 min / RPO ≤ 5 min em simulação.
Fase D: Rollout Gradual & Operação	Semanas 12 a 14	Estratégia de Canary Deployment (5% → 25% → 50% → 100% do tráfego) e operação assistida 24x7.	100% do tráfego migrado para produção com disponibilidade ≥ 99,95%.

Aprovação e Signatários do Relatório Final

Aprovado por: Comitê de Arquitetura de Soluções e Engenharia de Software — Bank OnlineX
Patrocinador do Projeto: Diretoria de Tecnologia e Operações Financeiras
Data de Homologação: Novembro de 2026 | Documento: POC-ARQ-ETAPA6-FINAL-v1.0