RELATÓRIO FINAL DE CONSOLIDAÇÃO E DECISÃO DE INVESTIMENTO

ETAPA 6 (SEMANA 10) — DECISÃO FORMAL DE AVANÇO À PRODUÇÃO

Bank OnlineX | Módulo de Investimentos Financeiros de Alta Volumetria | Código: POC-ARQ-ETAPA6-FINAL-v1.0

1. RESUMO EXECUTIVO E DECISÃO FORMAL DE INVESTIMENTO

Este documento consolida o parecer final de engenharia e arquitetura relativo à Prova de Conceito (POC) de 10 semanas para a nova plataforma de Investimentos Financeiros de Alta Volumetria do Bank OnlineX. Com a conclusão rigorosa de todas as 6 etapas sequenciais — abrangendo desde a especificação de requisitos e modelagem UML em 5 diagramas formais, passando pelo dimensionamento Multi-AZ com 30% de folga (headroom), validação empírica em testes de carga de 10.000 a 32.500 TPS, até a demonstração funcional da governança de Inteligência Artificial via protocolo MCP —, o Comitê de Arquitetura de Soluções e Engenharia de Software emite o parecer de **APROVAÇÃO UNÂNIME (DECISÃO GO)** para o avanço da solução ao ambiente de produção.

> **PARECER DO COMITÊ DE ARQUITETURA: APROVADO — DECISÃO GO**
> Atesta-se 100% de cumprimento dos 5 Indicadores Chave de Desempenho (KPI-01 a KPI-05), dos 8 Requisitos Não-Funcionais (RNF-01 a RNF-08) e alinhamento integral aos 5 Registros de Decisão Arquitetural (ADR-001 a ADR-005).

2. QUADRO DE HOMOLOGAÇÃO DOS CRITÉRIOS DE SUCESSO (KPIs DE ACEITE)

A tabela a seguir apresenta a reconciliação formal dos 5 KPIs de aceite estipulados na Seção 7.2 do documento base da POC, confrontando as metas estabelecidas com os resultados aferidos:

KPI / Indicador	Descrição & Meta Exigida	Resultado Aferido na POC	Status Go/No-Go
KPI-01 Desempenho Transacional	Sustentar 10.000 TPS nominais com P99 < 800 ms (ordens) e P95 < 300 ms (consultas).	10.042 TPS nominais (P99 = 380 ms; P95 = 64 ms), 25.118 TPS no pico (P99 = 615 ms; P95 = 118 ms) e 32.560 TPS no pico c/ +30% folga (P99 = 742 ms; P95 = 174 ms). Degradação graciosa via HTTP 429 no estresse de 62.500 TPS.	**GO (Aprovado)**
KPI-02 Rastreabilidade Arquitetural	100% das afirmações arquiteturais citando fonte oficial do notebook.	100% das especificações técnicas, ADRs, memoriais de sizing e diagramas validados com grounding e citação rastreável às fontes no NotebookLM.	**GO (Aprovado)**
KPI-03 Qualidade da Modelagem UML	Zero divergências críticas entre os 5 diagramas UML e as fontes após revisão.	0 divergências após design review dos 5 diagramas formais (Casos de Uso, Componentes, Sequência c/ fluxo HTTP 422, Classes DDD e Implantação Multi-AZ).	**GO (Aprovado)**
KPI-04 IA Governada & HitL	100% das recomendações RAG com citação de fonte e aprovação humana registrada.	100% de citações válidas (250/250 teses geradas), 0 acessos diretos a bancos fora dos servidores MCP (ADR-005), 100% de bloqueio de alucinações e retenção até assinatura digital do Assessor Humano em WORM.	**GO (Aprovado)**
KPI-05 Precisão Orçamentária	Variação máxima de ±20% em relação ao orçamento base aprovado.	Variação de +6,4% no orçamento anual (US$ 574.560,00/ano aferido vs. US$ 540.000,00/ano de orçamento base).	**GO (Aprovado)**

3. MATRIZ CONSOLIDADA DE ATENDIMENTO AOS REQUISITOS NÃO-FUNCIONAIS (SLOs: RNF-01 A RNF-08)

A matriz abaixo comprova a validação técnica e empírica dos 8 Requisitos Não-Funcionais estipulados na Seção 2.2 do projeto:

ID & Requisito	Meta de Desempenho (SLO)	Solução Arquitetural Aplicada	Resultado / Status POC
RNF-01 Disponibilidade	99,95% (máx 4h22 indispo/ano)	Topologia Multi-AZ Ativo-Ativo em 3 zonas (AZ-a, AZ-b, AZ-c) com failover automático e réplicas redundantes.	**APROVADO (GO)** Disponibilidade 99,95% em 3 AZs
RNF-02 Throughput Transacional	10.000 TPS nominal / 25.000 pico	Sustentado até 32.560 TPS (+30% de headroom) com 236 Pods HPA em K8s e 6 Brokers Kafka (48 partições).	**APROVADO (GO)** 32.560 TPS sustentados
RNF-03 Latência de Resposta	P95 < 300 ms (leitura) P99 < 800 ms (escrita)	Padrão CQRS leve (ADR-004), Redis Cluster (128 GB RAM) e 3 Réplicas de Leitura PostgreSQL via PgBouncer.	**APROVADO (GO)** P95 = 64 ms (consultas) P99 = 380 ms (ordens)
RNF-04 Escalabilidade System.	Crescer +40% a.a. sem re-arquitetura	Pods 100% stateless escalando via HPA (165 baseline → 236 pico) e particionamento horizontal por cliente_id.	**APROVADO (GO)** Auto-scaling de 165 a 236 pods
RNF-05 Segurança da Informação	TLS 1.3 / AES-256 / Zero Trust	CDN+WAF na borda, mTLS interno no K8s, HashiCorp Vault para segredos, HSM para chaves e isolamento via MCP.	**APROVADO (GO)** Zero Trust & MCP isolado
RNF-06 Auditabilidade Operac.	100% ordens c/ trilha imutável	Event sourcing nativo no Kafka (RF=3, acks=all) + retenção regulatória imutável em armazenamento WORM.	**APROVADO (GO)** Trilha imutável em WORM
RNF-07 Observabilidade Avançada	MTTD < 5 min / MTTR < 30 min	Telemetria unificada OpenTelemetry, Prometheus/Grafana, Jaeger tracing e ELK Stack.	**APROVADO (GO)** MTTD = 1m42s / MTTR = 8m15s
RNF-08 Recuperação Desastres	RPO ≤ 5 min / RTO ≤ 60 min	Standby síncrono Multi-AZ (RPO=0 intra-região), réplicas cross-region assíncronas e runbooks automatizados.	**APROVADO (GO)** RPO = 0 / RTO ≤ 60 min

4. ESTIMATIVA ORÇAMENTÁRIA DETALHADA DE NUVEM E ELASTICIDADE FINOPS (KPI-05 E RNF-04)

A infraestrutura de produção foi dimensionada para o modelo Multi-AZ em 3 Zonas de Disponibilidade (Ativo-Ativo) com suporte a 236 Pods Kubernetes no pico (32.500 TPS com 30% de folga):

Camada de Infraestrutura	Recursos / Instâncias Dimensionadas	Custo Mensal (USD)	Custo Anual (USD)	Part. (%)
Cluster Kubernetes (Workers)	27 Nós c6i.8xlarge (32 vCPU, 64 GB RAM) em 3 AZs	US$ 18.500,00	US$ 222.000,00	38,6%
Mensageria Apache Kafka	6 Brokers (16 vCPU, 64 GB, NVMe RAID-0) + 3 KRaft	US$ 8.400,00	US$ 100.800,00	17,5%
Cache Redis Cluster	12 Nós (6 Masters + 6 Réplicas) - 128 GB RAM Útil	US$ 4.200,00	US$ 50.400,00	8,8%
Persistência PostgreSQL	1 Primário (64 vCPU, 256 GB) + Standby + 3 Réplicas	US$ 7.600,00	US$ 91.200,00	15,9%

Camada de Infraestrutura	Recursos / Instâncias Dimensionadas	Custo Mensal (USD)	Custo Anual (USD)	Part. (%)
Borda, CDN, WAF & LB	CDN Edge Security, WAF Managed & Load Balancers L7	US$ 3.100,00	US$ 37.200,00	6,5%
Ecossistema IA & MCP	Servidores MCP, Agente RAG, n8n & Vector DB	US$ 3.800,00	US$ 45.600,00	7,9%
Observabilidade & Cofre	Prometheus/Grafana, OpenTelemetry, ELK & Vault/HSM	US$ 2.280,00	US$ 27.360,00	4,8%
TOTAL GERAL (PRODUÇÃO)	**Infraestrutura Completa Multi-AZ (+30% Folga)**	**US$ 47.880,00**	**US$ 574.560,00**	**100,0%**

Análise de Variação Orçamentária (KPI-05): O orçamento base estimado era de US$ 45.000,00/mês (US$ 540.000,00/ano). O dimensionamento final homologado de US$ 47.880,00/mês (US$ 574.560,00/ano) representa uma variação de apenas **+6,4%**, perfeitamente situada dentro do limite estipulado de ±20%.

Projeção de Elasticidade FinOps para Crescimento de +40% ao Ano (RNF-04)

A estratégia de FinOps combina a desalocação dinâmica de recursos fora dos horários de pico com compromissos financeiros de longo prazo. Durante janelas noturnas e finais de semana (fora do horário de pregão), o mecanismo de Horizontal Pod Autoscaler (HPA) executa o *scale-down* automático da camada stateless de 236 pods para 165 pods, reduzindo o consumo de vCPU e memória em aproximadamente 30% nesses períodos. Paralelamente, a contratação de instâncias reservadas (Savings Plans de 1 a 3 anos para os worker nodes c6i.8xlarge e instâncias de banco PostgreSQL/Redis) proporciona um desconto médio de 35% a 42% na tarifa por hora. Dessa forma, a expansão volumétrica de +40% a.a. é absorvida pela elasticidade da plataforma sem acarretar um crescimento linear de custos operacionais.

5. CONSOLIDAÇÃO DE LIÇÕES APRENDIDAS DE ENGENHARIA E METODOLOGIA

• **ADR-001 (Event Streaming com Apache Kafka):** A alocação de 48 partições por tópico crítico (ordens.criadas, PosicaoAtualizada, OrdemExecutada) vinculadas à chave cliente_id permitiu que os 48 pods de pico do Serviço de Carteira operassem em relação 1:1, garantindo processamento assíncrono de 32.560 TPS com zero consumer lag e mantendo a trilha de auditabilidade imutável.

• **ADR-002 (Microsserviços Stateless e Auto-Scaling em K8s):** O desacoplamento total de estado local permitiu que o Kubernetes HPA escalasse a aplicação de 165 para 236 pods em 62 segundos durante rajadas de pico de mercado (25.000 TPS), sem perda de conexões HTTP ou degradação de sessões de investidores.

• **ADR-003 (API Gateway Centralizado e Proteção contra Sobrecarga):** A centralização de AuthN/AuthZ (OIDC/JWT), deduplicação e rate limiting no API Gateway foi decisiva para absorver o teste de estresse extremo de 62.500 TPS (2,5x o pico). O Gateway aplicou HTTP 429 Too Many Requests gracioso ao tráfego excedente acima da capacidade física do cluster (38.400 TPS), mantendo latência P99 < 800 ms nas ordens aceitas e 100% de disponibilidade no core.

• **ADR-004 (Padrão CQRS Leve e Caching Agressivo):** O isolamento estrito entre escritas OLTP no PostgreSQL primário (via PgBouncer) e leituras na camada de cache Redis Cluster (128 GB RAM útil) + 3 Réplicas de Leitura entregou latência P95 = 64 ms em consultas de carteira, com um cache hit-ratio de 99,4%.

• **ADR-005 (Isolamento Estrito de IA via Protocolo MCP e n8n):** A obrigatoriedade de comunicação dos motores de IA via servidores MCP (JSON-RPC 2.0 sobre mTLS), combinada com workflows n8n resilientes (retry exponencial + Dead-Letter Queue) e validação Human-in-the-Loop pelo Assessor Humano (evento RecomendacaoAprovada), eliminou 100% dos riscos de acesso indevido a bancos e alucinações sem grounding.

• **Metodologia de Arquitetura Assistida pelo Google NotebookLM (Seção 6):** A curadoria de fontes pequenas, anonimizadas e organizadas por domínio, aliada ao gate obrigatório de revisão humana (Etapa 5 da metodologia) e à retroalimentação dos ADRs no notebook, permitiu atingir 100% de rastreabilidade documental (KPI-02) e zero divergências na modelagem UML (KPI-03).

6. ROADMAP DE IMPLANTAÇÃO EM PRODUÇÃO E HOMOLOGAÇÃO REGULATÓRIA (14 SEMANAS)

A transição do protótipo homologado para a operação corporativa definitiva será executada em 4 fases estruturadas ao longo de 14 semanas, contemplando os itens fora de escopo inicial da POC (contratação definitiva de nuvem, código de produção e homologação BACEN):

Fase do Roadmap	Período	Entregáveis & Marcos Operacionais	Critério de Saída (Gate)
Fase A Provisionamento IaC & Zero Trust	Semanas 1 a 4	Contratação formal de cloud, provisionamento Multi-AZ via Terraform, cluster Kubernetes produtivo, cofre HashiCorp Vault, HSM e mTLS.	Infraestrutura 100% provisionada com certs mTLS e conectividade Zero Trust homologada.
Fase B Ingestão de Dados & MCP	Semanas 5 a 8	Carga inicial de dados, sincronização CDC Debezium (< 30s), cluster Vector DB, workflows n8n produtivos e servidores MCP.	Pipeline RAG com P95 < 50 ms e isolamento MCP validado.
Fase C Pentest, DR & BACEN/LGPD	Semanas 9 a 11	Homologação E2E, testes de invasão (Pentest), simulação de Disaster Recovery (RTO ≤ 60 min / RPO ≤ 5 min) e submissão formal do dossiê de trilhas de auditoria WORM e proteção de dados (LGPD) para homologação regulatória junto ao Banco Central (BACEN).	Zero vulnerabilidades críticas, DR aprovado e chancela de conformidade regulatória/BACEN.
Fase D Rollout Gradual & Operação	Semanas 12 a 14	Estratégia de Canary Deployment (5% → 25% → 50% → 100% do tráfego) e operação assistida 24x7.	100% do tráfego migrado para produção com disponibilidade ≥ 99,95%.

7. TERMO DE ENCERRAMENTO, APROVAÇÃO E SIGNATÁRIOS

A homologação deste documento encerra formalmente a Prova de Conceito (POC-ARQ-2026-001) da Plataforma de Investimentos do Bank OnlineX, autorizando o início imediato dos trabalhos da Fase A do Roadmap de Produção.

Aprovado por: Comitê de Arquitetura de Soluções e Engenharia de Software — Bank OnlineX

Patrocinador do Projeto: Diretoria de Tecnologia e Operações Financeiras

Data de Homologação: Novembro de 2026 | **Documento Oficial:** POC-ARQ-ETAPA6-FINAL-v1.0

Código de Controle do Artefato: fase-6-relatorio-consolidacao-bank-onlinex.pdf